

# Compararea a Trei Metode pentru Detectarea Anomaliilor: CutPaste, PatchCore, PRN

Badea Cătălin-Gabriel 331AC

Decembrie 2025

## Introducere

Detectarea anomaliilor este un domeniu de o importanță majoră, contribuind la dezvoltarea rapidă a mai multor sectoare, cu costuri reduse. Modelele de învățare automată permit automatizarea și rezolvarea unor probleme repetitive, precum detectarea defectelor în domeniul industrial, aspect analizat în articolele studiate. De asemenea, sectorul medical beneficiază semnificativ de aceste progrese tehnologice, și nu numai.

## Contextul Articolelor

Ne vom concentra asupra a trei metode pentru detectarea anomaliilor: **CutPaste** (2021), **PatchCore** (2022) și **Prototypical Residual Networks – PRN** (2023). Aceste lucrări, publicate în conferința CVPR, au ridicat treptat standardul SOTA.

O problemă centrală în detectarea anomaliilor este lipsa imaginilor cu defecte pentru antrenament. Fiecare metodă propune soluții diferite pentru a combate acest neajuns. La baza evaluării modelelor stă setul de date **MVTec AD** [4], ce conține imagini industriale cu măști ce indică pixelii anormali.

Criteriile de evaluare includ **Image-AUROC** și **Pixel-AUROC**. PRN valorifică și metrici suplimentare precum **PRO** (coerența segmentării zonelor anormale) și **AP** (precizia identificării).

## Metoda 1: CutPaste

CutPaste [1] este un model *self-supervised* care generează singur exemple anormale, inspirat de predecesorul său, metoda Cutout.

Principiul său constă în a extrage bucăți dintr-o imagine și a le lipi în alte zone ale sale, pentru a modela erori mai complexe decât umplerile uniforme de culoare, utilizate în trecut. Acest proces permite

modelului să evite generalizări naive și să învețe mai bine ce reprezintă caracteristici normale.

Modelul utilizează un ResNet-18 preantrenat pe ImageNet pentru extragerea trăsăturilor, la care ulterior este adăugat un MLP pentru proiectarea acestora într-un spațiu latent mai discriminativ în etapa de antrenare.

Metoda folosește două tipuri de inserții: **patch** (bucăți mari, simulând defecte structurale) și **scar** (fâșii subțiri, simulând zgârieturi). Autorii au introdus astfel o clasificare tripartită, ceea ce a oferit rezultate mai bune decât clasificarea binară normal/anormal.

Ei au observat că zonele detectate ca anormale nu coincid cu anomaliile reale, însă sunt suficient de distincte și separate de zonele normale. Astfel, deși modelul identifică anomalii diferite de cele efective, acesta reușește să separe eficient regiunile anormale de cele normale.

### Avantaje:

- Ușor de implementat și înțeles.
- Nu necesită imagini reale cu defecte.
- Timp de inferență scurt.

### Dezavantaje:

- Necesită timp de antrenare.
- Localizare mai imprecisă.
- Este destul de naiv în practică, mai puțin matematic.

## Metoda 2: PatchCore

PatchCore [2] este o metodă *unsupervised* care se diferențiază complet de CutPaste. În loc să genereze exemple anormale, modelul procesează imaginile existente, le împarte în patch-uri și extrage caracteristici folosind un WideResNet-50 preantrenat pe ImageNet.

Din toate fragmentele extrase, modelul le selectează pe cele mai reprezentative printr-un algo-

ritm (greedy) iterativ, numit coreset: se alege un patch, apoi cel mai îndepărtat de acesta, apoi cel mai îndepărtat de ambele și tot așa, până la aproximativ **10% din memoria totală**, optim detectat experimental. Această strategie reduce redundanța, economisește memorie, scade timpul de inferență și acoperă uniform spațiul datelor.

La apariția unei imagini noi, aceasta este împărțită în fragmente, fiecare fiind comparat cu memoria de referință prin metoda KNN. Dacă un patch se potrivește suficient de bine cu cele normale, este considerat normal; altfel, este marcat ca anormal. Acest proces permite generarea unui **heatmap** care evidențiază zonele defectuoase, iar imaginea întreagă este clasificată ca anormală dacă cel puțin un fragment este detectat ca fiind anormal.

#### Avantaje:

- Nu necesită antrenare.
- Nu necesită anomalii artificiale.
- Foarte practic, cu rezultate excelente.

#### Dezavantaje:

- Necesită o memorie considerabilă pentru stocarea caracteristicilor extrase.
- Timp de inferență mai mare.
- Algoritmul este destul de *brute-force* și mai puțin elegant.

## Metoda 3: PRN (Prototypical Residual Networks)

PRN [3] este un model avansat, combinând concepte de învățare *self-supervised* și *supervised*.

Spre deosebire de PatchCore, PRN păstrează în memorie prototipuri, reprezentări generalizate ale caracteristicilor normale, ceea ce reduce semnificativ spațiul necesar. Imaginile normale sunt trecute tot printr-un ResNet-18 preantrenat pe ImageNet, iar vectorii de feature-uri extrași din primele trei blocuri ale rețelei sunt folosiți pentru a construi spațiul prototipurilor. Această selecție din mai multe straturi captează atât trăsături fine cât și structuri mari pentru diverse defecte, evitând layer-urile finale orientate

pe recunoaștere, iar prototipurile sunt filtrate prin KNN pentru a păstra doar cele mai reprezentative 10%, reducând memoria necesară și mai mult.

PRN integrează și un proces de multi-scale fusion, care combină informațiile de la diferite straturi, demonstrându-se crucial pentru performanța ridicată a modelului.

În plus, pentru a crește robustețea, metoda generează defecte artificiale, similar CutPaste, dar într-un mod mai inteligent: zonele cu defecte reale sunt transformate prin rotire, recolorare și inserție doar în regiuni în care este normal să apară; Defecte noi sunt generate cu Perlin noise, pentru a simula anomalii neîntâlnite.

La inferență, se calculează distanța dintre feature-urile imaginii transformate și cel mai apropiat prototip, iar rezidul rezultat determină scorul de anomalie.

#### Avantaje:

- Mai robust la variații de fundal și de iluminare.
- Heatmap extrem de precis.
- Memorie minimă datorită prototipurilor.
- Model matematic elegant și robust.

#### Dezavantaje:

- Arhitectură mai complexă, mai greu de antrenat.
- Necesită mai multe resurse GPU și timp de antrenare.

## Concluzii

Fiecare metodă are rolul său: CutPaste este un bun punct didactic, PatchCore este solid și rapid pentru aplicații industriale, iar PRN oferă precizie maximă și heatmap-uri detaliate, fiind potrivit acolo unde acuratețea localizării defectelor este crucială. Mai jos, Tabelul 1 prezintă câteva informații generale pentru o privire de ansamblu.

Alegerea depinde de necesitatea rapidității versus precizia localizării și resursele disponibile, rezultatele tuturor fiind comparabile. Totuși PatchCore reprezintă un standard dificil de depășit, datorită combinației dintre eficiența practică și precizia ridicată.

Metodă	Im-AUC	PRO	Tip	Training	Memory	Backbone
CutPaste	96.6%	-	self-supervised	da	-	ResNet-18
PatchCore	99.1%	93.5%	unsupervised	nu	coreset	WideResNet-50
PRN	99.4%	96.1%	supervised	da	prototipuri	ResNet-18

Tabelul 1: Compararea performanței și a caracteristicilor principale ale metodelor.

## Referințe Bibliografice

- [1] C.-L. Li, K. Sohn, J. Yoon, and T. Pfister, “Cut-Paste: Self-Supervised Learning for Anomaly Detection and Localization,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 9677–9686.
- [2] K. Roth, L. Pemula, J. Zepeda, B. Schölkopf, T. Brox, and P. Gehler, “Towards Total Recall in Industrial Anomaly Detection,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 14318–14328.
- [3] H. Zhang, Z. Wu, Z. Wang, Z. Chen, and Y.-G. Jiang, “Prototypical Residual Networks for Anomaly Detection and Localization,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 16281–16291.
- [4] P. Bergmann et al., “MVTec AD — A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection,” in *CVPR*, 2019.

Dataset: <https://www.mvtec.com/company/research/datasets/mvtec-ad/>